

SRPO: Self-Referential Policy Optimization for Vision-Language-Action Models

충북대학교 AI Cross-lab tech seminar

문서영 (Dai Lab)

2026.7.24

Email: yungum0531@gmail.com

Table of contents

I . 개인 연구 분야

II . 논문리뷰: 요약

III . 논문리뷰: 배경


IV . 논문리뷰: Method

V . 논문리뷰: Experiments

VI . 논문리뷰: Limitations & Personal opinions

- Learning from reasoning processes instead of final answers
-
- - Dense Reward
- - Better Sample Efficiency
- - More Reliable Reasoning
-

- 논문 제목: SRPO: Self-Referential Policy Optimization for Vision-Language-Action Models
- 저자 및 출판 정보
 - 예시: Shiduo Zhani et al., Fudan University, CVPR 2025
- Contributions
 - (1) Online Post-Training 효과 입증
 - (2) Reward Design (보상 설계)의 우수성. → 조밀한 지도 신호로 과정에 대한 보상 부여
 - (3) 제한된 입력만으로 SOTA 성능 → 시각 입력만으로 SOTA 달성, 실용성 높다.
 - (4) SRPO는 One-Shot SFT의 다양성 한계를 극복한다
 - (5) 교란 데이터 설정에서도 Full-Shot SFT를 능가한다.



3.1 Problem Formulation and Key Components

관측함수 $o_t = O(z_t),$

행동 생성 함수 $a_t \sim \pi_{\theta}(\cdot \mid o_t, l),$

환경 함수 $z_{t+1} \sim E(\cdot \mid z_t, a_t)$



3.2 Problem Formulation and Key Components

$\hat{R}(o_{0:T}, \mathcal{S})$, where $\mathcal{S} = \{o_{0:T}^{(i)}; R(z_{0:T}^{(i)}, l) = 1, \forall i\}$

$R^{\wedge}$: 실패 궤적 보상

$\mathcal{S}$: 보상이 1일때, 즉 성공일때의 관측 집합(성공 참조 궤적)

$h_i = W(o_{0:T}^{(i)})$

World Model encoder(W)로 궤적 인코딩


$C = \text{DBSCAN}(\mathcal{S})$

$d_i = \min(\{ \|h_i - h_j\|^2; h_j \in C \})$

성공 궤적을 월드 모델 잠재 공간에서 군집화

$g_i = \begin{cases} 1.0 & \text{for succes trajectory} \\ \phi(\frac{d_i - \bar{d}}{\sigma_d}) & \text{for failed trajectory} \end{cases}$

실패 궤적과 성공 궤적 군집의 중심간 거리 계산



3.3 Self-Referential Policy Optimization

Probability ratio,
advantage,
KL term

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(a_t^{(i)} | o_t^{(i)}, l)}{\pi_{\theta_{\text{old}}}(a_t^{(i)} | o_t^{(i)}, l)}, \quad \hat{A}_i = \frac{g_i - \mu_g}{\sigma_g}, \quad \omega(\theta) = \beta D_{\text{KL}}(\pi_{\theta} \| \pi_{\text{ref}}) \quad (6)$$

클리핑 함수

$$\mathcal{L}_{t,i}^{\text{CLIP}}(\theta) = \min \left(r_{i,t}(\theta) \hat{A}_i, \text{clip}(r_{i,t}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i \right)$$

SRPO 목적 함수

$$\mathcal{L}_{\text{SRPO}}(\theta) = \mathbb{E}_{t,i} \mathcal{L}_{t,i}^{\text{CLIP}}(\theta) + \omega(\theta)$$

$$\mu_{\hat{R}} = \frac{1}{M} \sum_{j=1}^M \hat{R}_j, \quad \sigma_{\hat{R}} = \sqrt{\frac{1}{M} \sum_{j=1}^M (\hat{R}_j - \mu_{\hat{R}})^2 + \epsilon}$$

LIBERO

T: third-view image (제3자 시점 영상)
l: language description (언어 설명)

PPO

GRPO

월드 모델을 시뮬레이터로 활용

Model	Policy Input	LIBERO				
		Spatial	Object	Goal	Long	Avg
OpenVLA (Kim et al., 2024)	T+I	84.7	88.4	79.2	53.7	76.5
Pi0+fast (Pertsch et al., 2025)	T+W+P+I	96.4	96.8	88.6	60.2	85.5
Pi0 (Black et al.)	T+W+P+I	96.8	98.8	95.8	85.2	94.2
SmolVLA (Shukor et al., 2025)	T+W+P+I	93.0	94.0	91.0	77.0	88.8
WorldVLA (Cen et al., 2025)	T+I	85.6	89.0	82.6	59.0	79.1
NORA (Hung et al., 2025)	T+I	92.2	95.4	89.4	74.6	87.9
CoT-VLA (Zhao et al., 2025)	T+I	87.5	91.6	87.6	69.0	81.1
UniVLA (Bu et al., 2025)	T+I	96.5	96.8	95.6	92.0	95.2
TraceVLA (Zheng et al., 2024)	T+I	84.6	85.2	75.1	54.1	74.8
MolmoAct (Lee et al., 2025)	T+I	87.0	95.4	87.6	77.2	86.6
ThinkAct (Huang et al., 2025)	T+I	88.3	91.4	87.1	70.9	84.4
GR00T N1 (Bjorck et al., 2025)	T+I	94.4	97.6	93.0	90.6	93.9
3D-CAVLA (Bhat et al., 2025)	T+W+P+D+I	98.2	99.8	98.2	96.1	98.1
OpenVLA-OFT (Kim et al., 2025)	T+W+P+I	96.2	98.3	96.2	90.7	95.3
OpenVLA*-Full	T+I	91.6	95.3	90.6	86.5	91.0
TGRPO (Chen et al., 2025b)	T+I	90.4	92.2	81.0	59.2	80.7
GRAPE (Zhang et al., 2024)	T+I	88.5	92.1	83.1	57.2	80.2
VLA-RL (Lu et al., 2025)	T+I	90.2	91.8	82.2	59.8	81.0
World-Env (Xiao et al., 2025)	T+I	87.6	86.6	86.4	57.8	79.6
SimpleVLA-RL (Li et al., 2025)	T+I	98.2	98.7	98.8	91.7	96.9
RIPT-VLA (Tan et al., 2025)	T+W+P+I	99.0	98.6	98.6	93.8	97.5
RLinf (Zang et al., 2025)	T+W+P+I	99.4	99.8	98.8	94.0	98.0
OpenVLA*-One	T+I	63.6	54.9	59.6	17.3	48.9
+ Offline SRPO	T+I	92.5	96.8	92.0	88.7	92.5
		↑28.9	↑41.9	↑32.4	↑71.4	↑43.6
+ Online SRPO	T+I	98.8	100.0	99.4	98.6	99.2
		↑35.2	↑45.1	↑39.8	↑81.3	↑50.3

■ Limitations

- 초기 성공 궤적 부재 시의 콜드 스타트 (Cold-start Problem)
- DBSCAN 군집화 및 인코딩 연산 병목
- 하위 최적(Sub-optimal) 군집에의 매몰 가능성

■ Personal opinions

한계1. 자기 참조 궤적 보상을 선택하여, worst case에서 성공 궤적이 희소한 과제일때, 학습의 불가능과 효율성 저하가 사료됨

한계2. DBSCAN은 과제별 엡실론 과 파라미터 튜닝이 번거롭다. 하이퍼 파라미터 의존성이 적은 Black Hole Clustering을 도입하면 연산량을 유지하면서 범용성이 개선될 것이다.

한계3. 보상 모델 연산량: 본 논문의 한계는 무거운 비디오 인코더 연산량 $O(T^2 P^2)$ 이다.

한계4. 성공궤적의 신뢰성 검증 과정 없음

Thank you for attention

SRPO: Self-Referential Policy Optimization for Vision-Language-Action Models

Q&A time

충북대학교 AI Cross-lab tech seminar